

Consumo eléctrico residencial: miniproyecto de series temporales y pronóstico

1. Introducción y planteamiento del problema

El consumo eléctrico residencial es una variable relevante para analizar el uso de energía dentro de una vivienda y anticipar posibles patrones de demanda. En este proyecto se trabaja con el dataset **Appliances Energy Prediction**, en una versión adaptada para el curso, con el objetivo de construir modelos de forecasting capaces de predecir el consumo de energía de electrodomésticos.

La variable temporal del dataset es `fecha` y la variable objetivo es `consumo_electrodomesticos`. Los datos originales se encuentran registrados cada 10 minutos, pero para este trabajo se utiliza una frecuencia horaria. El horizonte de predicción definido es de 24 horas, por lo que el objetivo principal es estimar el consumo de electrodomésticos de las próximas 24 horas a partir de la información histórica disponible.

El problema se aborda como una serie temporal, ya que el orden cronológico de las observaciones es fundamental. Primero se construyen modelos univariantes, utilizando únicamente la historia de la variable objetivo. Luego se analiza la posible incorporación de variables exógenas, como temperatura, humedad, presión atmosférica, velocidad del viento y punto de rocío.

2. Descripción del dataset

El dataset contiene 19.735 registros y 9 variables. La variable `fecha` representa el momento de cada medición, mientras que `consumo_electrodomesticos` corresponde al consumo de energía de los electrodomésticos de la vivienda. Además, el conjunto incluye variables ambientales interiores y exteriores: `temperatura_zona_1`, `humedad_zona_1`, `temperatura_exterior`, `presion_atmosferica`, `humedad_exterior`, `velocidad_viento` y `punto_rocio`.

Durante la revisión inicial se identificaron valores faltantes en 24 filas, equivalentes aproximadamente al 0,12 % del dataset. Debido a que se trata de una serie temporal, se decidió imputar estos valores en lugar de eliminar registros, para evitar huecos temporales que pudieran afectar el análisis y el modelado.

3. Metodología

La metodología comenzó con la conversión de la variable `fecha` a formato `datetime`, el ordenamiento cronológico de las observaciones y la definición de la fecha como índice temporal. También se verificó la ausencia de duplicados y huecos temporales, ya que una serie temporal debe mantener una estructura ordenada y continua.

Para tratar los valores faltantes se compararon distintos métodos de imputación, entre ellos interpolación lineal, interpolación cuadrática, forward fill y backward fill. Finalmente, se utilizó interpolación lineal porque ofrecía una transición simple y conservadora entre observaciones cercanas, sin introducir trayectorias artificiales en los bloques de datos faltantes.

Luego se realizó un resampling de frecuencia original de 10 minutos a frecuencia horaria. Para `consumo_electrodomesticos` se aplicó suma, ya que representa consumo acumulado dentro de la hora. Para las variables ambientales se utilizó media, porque variables como temperatura, humedad, presión y viento representan condiciones promedio del intervalo y no cantidades acumulables.

Posteriormente se realizó un análisis exploratorio de la serie temporal. Se analizaron gráficos de la variable objetivo, media móvil de 24 horas, tendencia lineal, descomposición de tendencia-estacionalidad-residuo, estacionariedad mediante test ADF, patrones por hora y día de semana, outliers y autocorrelación mediante ACF y PACF.

Para el modelado se separaron los datos respetando el orden temporal: el 80 % inicial se utilizó como entrenamiento y el 20 % final como prueba. Esta decisión evita fuga de información futura hacia el entrenamiento. Se probaron modelos univariantes con `skforecast`, comparando la estrategia recursiva y la estrategia directa. Luego se aplicó backtesting dentro del conjunto de entrenamiento y Grid Search para ajustar lags e hiperparámetros del modelo Random Forest.

4. Resultados y discusión

El análisis exploratorio mostró que el consumo horario presenta alta variabilidad y picos puntuales. La media móvil de 24 horas permitió suavizar la serie y observar mejor el comportamiento general. La tendencia lineal no evidenció un crecimiento o decrecimiento fuerte, aunque sí se observaron fluctuaciones locales. La descomposición mostró un patrón estacional repetitivo asociado a ciclos horarios, mientras que los residuos concentraron variaciones irregulares y picos no explicados por la tendencia ni la estacionalidad.

El test de Dickey-Fuller aumentado arrojó un p-value menor a 0,05, por lo que se rechazó la hipótesis nula de raíz unitaria y se concluyó que la serie presenta evidencia de estacionariedad. Aun así, la serie mantiene ruido, variabilidad y picos relevantes propios del consumo eléctrico residencial.

El análisis por hora del día mostró que el consumo tiende a ser menor durante la madrugada y aumenta durante las horas de actividad, con picos especialmente en la tarde. El análisis por día de semana mostró diferencias menos marcadas, aunque se observaron mayores consumos promedio los lunes y sábados. También se detectaron 346 valores atípicos, equivalentes al 10,52 % de las observaciones. Estos outliers no fueron eliminados

automáticamente, porque pueden representar consumos reales asociados al uso simultáneo de electrodomésticos o cambios puntuales en los hábitos de la vivienda.

En la etapa de modelado se compararon dos estrategias univariantes. El modelo recursivo base obtuvo un MAE de 326,20 y un RMSE de 543,31 en la primera predicción de 24 horas sobre test. El modelo directo base obtuvo un MAE de 341,41 y un RMSE de 496,59. Según MAE, el modelo recursivo tuvo un desempeño inicial levemente mejor, aunque esta comparación se tomó solo como referencia preliminar.

Para realizar una evaluación más robusta se aplicó backtesting dentro del conjunto de entrenamiento. Luego se ejecutó Grid Search sobre distintas ventanas de lags y configuraciones del Random Forest. La mejor configuración encontrada fue un modelo recursivo con 72 lags, 200 árboles y profundidad máxima de 10. Esta configuración obtuvo un MAE de 238,89 en validación temporal interna.

Finalmente, el modelo recursivo ajustado se evaluó sobre el conjunto de test, sin modificar lags ni hiperparámetros. El resultado final fue un MAE de 210,21, el menor error observado en la comparación. Esto indica que el ajuste de hiperparámetros mejoró la capacidad predictiva del modelo y que la historia reciente del consumo contiene información útil para predecir las próximas 24 horas.

5. Conclusiones

El proyecto permitió desarrollar un flujo completo de forecasting aplicado al consumo eléctrico residencial. Se preparó la serie temporal, se trataron valores faltantes, se transformó la frecuencia original a frecuencia horaria, se realizó análisis exploratorio y se entrenaron modelos univariantes con validación temporal.

El mejor modelo encontrado fue el modelo recursivo ajustado con Random Forest, utilizando 72 lags, 200 árboles y profundidad máxima de 10. Este modelo obtuvo un MAE final de 210,21 en test, por lo que fue seleccionado como el mejor modelo univariante. El resultado muestra que los valores pasados del consumo son útiles para anticipar el consumo futuro en un horizonte de 24 horas.

Sin embargo, el modelo presenta limitaciones. La serie tiene alta variabilidad y picos abruptos que pueden depender de hábitos específicos de los usuarios, los cuales no siempre están representados en los datos. Además, aunque el modelo univariante tuvo buen desempeño, una posible mejora futura sería incorporar variables exógenas ambientales y comparar si aportan información adicional. En un escenario real, esas variables futuras deberían estar disponibles mediante mediciones o pronósticos externos.

6. Referencias

Géron, A. (2023). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems* (3rd ed.). O'Reilly Media.

Alpaydin, E. (2020). *Introduction to Machine Learning* (4th ed.). MIT Press.

Kelleher, J. D., Namee, B. M., & D'Arcy, A. (2020). *Fundamentals of Machine Learning for Predictive Data Analytics* (2nd ed.). MIT Press.